

人机信任调控因素及试验设计参考

本材料结合传感器任务和威胁排序任务中的现有实现，归纳可供类似试验参考的调控因素、触发依据和评价口径。调控目标是帮助操作者合理采纳或拒绝人工智能（AI）建议，减少欠信任与过信任。现有功能可提炼为五类因素，具体效果及适用条件仍需通过试验验证。

一 调控因素及其作用方式

1 AI 能力信息呈现

向操作者展示 AI 能力等级对应的准确率参考值及波动范围，为判断系统能力提供信息。可设置不展示、展示单一参考值、展示参考值及波动范围等试验条件，考察能力信息对建议采纳和信任判断的影响。当前曲线按 AI 等级概率范围生成，应明确标注为能力参考，不能作为实测历史正确率。

2 决策信息透明度

在推荐结果之外展示目标观测信息。传感器任务包括方位、距离、速度、航向及数据时间等信息，并提供候选目标列表；威胁排序任务包括威胁类别、目标特征、距离及数据时间等信息。可比较仅展示推荐结果与同时展示相关观测信息的条件。当前实现属于信息辅助，不等同于完整的 AI 推理过程解释。

3 注意引导

进入信任支持状态后，对 AI 推荐区域进行高亮，引导操作者关注推荐信息；聚焦推荐目标或开始人工复核后结束高亮。可将是否高亮、触发时机和结束条件作为试验变量，考察推荐信息的注意分配和查看行为。

4 人工复核支持

通过专用按键查看 AI 推荐目标的观测信息，记录有效复核次数、持续时间及无有效推荐时的复核操作。可比较是否提供复核入口或不同复核方式的影响。当前复核用于辅助判断，不能直接等同于操作者已经理解信息，也不能仅凭复核次数判断信任是否适当。

5 人机分歧对比

当人工选择与 AI 推荐不一致时，并列展示两个目标的观测信息，支持操作者比较差异。可设置是否提供对比、对比字段范围等条件，考察分歧后的选择调整和最终决策。人机选择不一致只表示发生分歧，不应直接判定为欠信任。

以上试验变量由现有功能提炼而来，供试验设计选取；不代表当前系统已具备各因素的独立开关，也不代表已完成单因素效果验证。

二 试验条件与调控触发

试验条件建议至少记录任务类型、任务难度、AI 能力等级和操作模式。操作模式可区分作业人员独立操作、智能体自主操作和人机协同操作。涉及 AI 建议采纳或拒绝的信任行为分析，应限定在操作者有机会作出相关选择的条件下；练习阶段与正式试验阶段应分别记录。

当前调控依据同一被试、同一任务类型、同一任务难度和同一 AI 等级的历史结果，统计信任适当、欠信任和过信任情况。历史中出现欠信任或过信任后进入信任支持状态，两类偏差目前采用共同的支持模式。该规则是现有实现口径，不能表述为已经验证的最优触发阈值，也不宜描述为两套已独立验证的定向干预策略。

对方设计试验时，可先比较基础界面与调控界面的整体效果，再按研究目的拆分能力信息、透明度、注意引导、复核支持和分歧对比等因素。建议明确每项因素的启用条件、呈现内容和结束条件，避免多个因素同时变化后难以判断效果来源。

三 评价指标与判定口径

1 信任行为结果

以 AI 推荐、人工最终选择和任务真值为判定依据：AI 正确且人工采纳，记为信任适当；AI 正确但人工拒绝，记为欠信任；AI 错误且人工采纳，记为过信任；AI 错误而人工拒绝，记为信任适当。此处“适当”评价的是对 AI 建议的依赖行为。人工拒绝错误建议后仍可能选错，因此必须另行统计任务正确率。

分别计算信任适当率、欠信任率和过信任率，分母为能够完成上述判定的有效试次。AI 推荐、人工最终选择或任务真值缺失时，不宜强行归类，应单独记录缺失原因。

2 任务绩效与过程行为

任务绩效可记录最终选择正确率及决策耗时；决策耗时应统一起止事件，例如从 AI 推荐呈现到人工最终确认。过程行为可记录人工复核次数和时长、观测信息查看时长、人机分歧对比的出现与持续时间、选择变化以及相关区域的眼动行为。过程指标用于解释调控如何影响决策，不直接替代信任结果判定。

3 主观评价

可结合研究目的配置任务组结束后的信任问卷，将主观信任与行为信任分别分析，并统一施测时点。问卷呈现与问卷提交应分别记录，避免将已触发但未提交的问卷计入有效样本。

四 试验记录与使用边界

建议按试次关联被试标识、任务组及试次标识、任务条件、调控因素及参数、实际触发记录、AI 推荐、人工最终选择、任务真值和关键事件时间。问卷及眼动数据通过相应标识与任务记录关联，以支持比较调控前后的行为和绩效。

本材料可作为类似试验的因素选取和记录口径参考。迁移时需结合对方任务中的可观测信息、真值定义和人工决策权限细化方案；调控是否有效、适用于何种被试与任务，以及各因素是否存在交互作用，应以相应试验结果为依据。